



PREDICTION USED CAR PRICES USING LINEAR REGRESSION VS RANDOM FOREST REGRESSION

Comparative Study of Linear Regression and Random Forest Regression for Used Car Price Prediction

DATA ANALYTICS



MACHINE
LEARNING



DATA
ANALYSIS



FEATURE
ENGINEERING



BIG
DATA



PRICE
PREDICTION



ACCURACY
OPTIMIZATION



BETTER
DECISION




BUSINESS
VALUE

MODEL COMPARISON

LINEAR REGRESSION




RANDOM FOREST REGRESSION



R ² Score	0.63	0.87
MAE	2,145	1,245
RMSE	3,124	1,912

RANDOM FOREST REGRESSION



PRESENTED BY



M. Taufiq Ridwan



Darul Setiawan



Anang Santoso



Reza Fabian



Joko

USED CAR DEALER

CERTIFIED
QUALITY

USED CAR MARKET GROWTH
(Global Trend)



MARKET
GROWTH
+12.4%
YoY


PRICE
\$ 18,450

AI


AI DASHBOARD



PRICE TREND ANALYSIS



SCATTER PLOT (Example)



KEY FACTORS



YEAR



BRAND



MODEL



CONDITION



ODOMETER



MMR



LOCATION

BACKGROUND OF THE STUDY



1. PERTUMBUHAN PASAR MOBIL BEKAS

- Permintaan mobil bekas terus meningkat karena harga kendaraan baru semakin tinggi.
- Harga mobil bekas dipengaruhi oleh banyak faktor sehingga sulit diprediksi secara manual.



2. PERMASALAHAN

Harga kendaraan dipengaruhi oleh berbagai variabel seperti:

- Tahun produksi
- Merek kendaraan
- Model kendaraan
- Kondisi kendaraan
- Odometer
- Nilai pasar (MMR)
- Lokasi penjualan

Hubungan antar variabel tidak selalu linear sehingga metode statistik sederhana belum tentu menghasilkan prediksi terbaik.



3. SOLUSI

Machine Learning mampu:

- ✓ menemukan pola kompleks
- ✓ meningkatkan akurasi prediksi
- ✓ membantu dealer menentukan harga jual
- ✓ membantu pembeli memperoleh estimasi harga yang wajar



4. TUJUAN PENELITIAN

Membandingkan performa dua algoritma:

- 1 Linear Regression
- 2 Random Forest Regression

untuk menentukan model yang memberikan prediksi harga mobil bekas paling akurat.

ALUR PENELITIAN



1. DATASET



2. PREPROCESSING



3. FEATURE
ENGINEERING



4. LINEAR
REGRESSION



5. RANDOM FOREST
REGRESSION



6. PRICE
PREDICTION


DATASET SUMMARY

DATASET OVERVIEW

558,837
TOTAL RECORDS

16
FEATURES

RECORDS OVER TIME



car_prices.csv

CSV

DATA TYPES



MISSING VALUES

0.21%

FEATURE ENGINEERING



CLEANING



ENCODING



SCALING




TRANSFORMATION

PRICE DISTRIBUTION



SCATTER PLOT (Example)



DECISION TREE (Example)



DATASET PIPELINE



DATA COLLECTION



DATA CLEANING



EXPLORATORY ANALYSIS



FEATURE ENGINEERING



MODEL BUILDING



PRICE PREDICTION

RINGKASAN DATASET (SUMBER: KAGGLE)

Dataset berisi sekitar 558.837 data transaksi mobil bekas dengan 16 variabel, sehingga cocok untuk membangun dan mengevaluasi model prediksi harga.



TARGET VARIABLE
SELLING PRICE

Harga jual aktual kendaraan yang akan diprediksi.

FEATURE UTAMA

VARIABEL	DESKRIPSI	VARIABEL	DESKRIPSI
year	Tahun produksi kendaraan	odometer	Jarak tempuh kendaraan
make	Merek kendaraan	color	Warna eksterior
model	Model kendaraan	interior	Warna interior
trim	Varian kendaraan	seller	Penjual
body	Jenis bodi kendaraan	mmr	Manheim Market Report (estimasi nilai pasar)
transmission	Jenis transmisi	saledate	Tanggal transaksi
state	Negara bagian/lokasi penjualan		
condition	Nilai kondisi kendaraan		

INSIGHT DATASET

- ✓ Dataset berskala besar (lebih dari 550 ribu observasi)
- ✓ Memiliki kombinasi variabel numerik dan kategorikal
- ✓ Cocok untuk supervised learning (regression)
- ✓ Mengandung fitur yang berpotensi memiliki hubungan linear maupun non-linear terhadap harga kendaraan
- ✓ Sangat sesuai untuk membandingkan performa Linear Regression dan Random Forest Regression



RECORDS
558,837



FEATURES
16



MISSING VALUES
0.21%




DATA TYPES

- Numeric
- Categorical
- Date



SOURCE
KAGGLE

DATASET PREPROCESSING



TAHAPAN PREPROCESSING

1



CHECK MISSING VALUE

Memeriksa nilai yang hilang (missing value) pada setiap kolom untuk menentukan strategi penanganan yang tepat.

2



CHECK DUPLICATE DATA

Mendeteksi dan mengevaluasi data duplikat agar tidak menyebabkan bias pada model.

3



MENGHAPUS KOLOM YANG TIDAK DIGUNAKAN

Menghapus kolom yang tidak relevan atau tidak memberikan kontribusi terhadap prediksi harga mobil.

4



MENENTUKAN TARGET

Menetapkan variabel target yaitu "Selling Price" sebagai nilai yang akan diprediksi.

5



ENCODING DATA KATEGORIKAL

Mengubah variabel kategorikal menjadi representasi numerik menggunakan teknik encoding (Label / One-Hot Encoding).

6



MEMISAHKAN FITUR DAN TARGET

Memisahkan variabel independen (fitur) dan variabel dependen (target) sebelum proses pemodelan.

7



SPLIT DATA

Membagi data menjadi data latih (train) dan data uji (test) untuk evaluasi performa model.

8



MEMISAHKAN KOLOM NUMERIK DAN KATEGORIKAL

Memisahkan kolom berdasarkan tipe data untuk memudahkan pemrosesan dan transformasi yang sesuai.

9



PIPELINE PREPROCESSING

Membangun pipeline preprocessing untuk memastikan proses transformasi data konsisten dan dapat direplikasi saat prediksi.

AI

EXPLORATORY DATA ANALYSIS (EDA)



DATASET OVERVIEW

558,837

TOTAL RECORDS

16

FEATURES


SOURCE

KAGGLE

STATISTIK DESKRIPTIF (VARIABEL NUMERIK)

Variabel	Count	Mean	Std	Min	25%	50% (Median)	75%	Max
year	558,837	2010.72	7.46	1970	2008	2013	2016	2024
odometer (mile)	558,837	93,395.33	59,811.79	1	43,000	84,972	134,500	999,999
mmr	558,837	10,388.70	6,157.17	500	6,150	9,150	13,900	99,000
sellingprice (USD)	558,837	12,592.91	7,681.38	850	7,250	10,995	16,395	123,456

DISTRIBUSI SELLING PRICE (USD)



Min \$850 25% \$7,250 50% \$10,995 75% \$16,395 Max \$123,456

CORRELATION MATRIX (NUMERICAL FEATURES)


	year	odometer	mmr	sellingprice
year	1.00	-0.57	0.58	0.69
odometer	-0.57	1.00	-0.60	-0.42
mmr	0.58	-0.60	1.00	0.86
sellingprice	0.69	-0.42	0.86	1.00



INSIGHT CORRELATION

- sellingprice berkorelasi positif kuat dengan mmr (0.86) dan year (0.69).
- sellingprice berkorelasi negatif dengan odometer (-0.42).

DISTRIBUSI ODOMETER (MILE)



Min 1 25% 43,000 50% 84,972 75% 134,500 Max 999,999

RATA-RATA HARGA (SELLING PRICE) BERDASARKAN TAHUN PRODUKSI



INSIGHT UTAMA

- ✓ Harga jual (selling price) memiliki distribusi right-skewed.
- ✓ Odometer juga right-skewed, mayoritas mobil memiliki jarak tempuh rendah hingga menengah.
- ✓ Korelasi menunjukkan mmr adalah prediktor



MODELLING MENGGUNAKAN RANDOM FOREST REGRESSION



HASIL RANDOM FOREST REGRESSION



MAE
918.8771979039855
Mean Absolute Error



RMSE
1522.032298276469
Root Mean Squared Error




R² SCORE
0.974512231303514
Coefficient of Determination

RINGKASAN PERFORMA MODEL

Random Forest Regression menunjukkan performa yang sangat baik dengan error rendah dan R² yang lebih tinggi dibanding Linear Regression.



RANDOM FOREST: AKTUAL VS PREDIKSI



PERFORMA MODEL SANGAT BAIK

Random Forest Regression memberikan prediksi yang sangat akurat dengan error rendah dan R² tinggi, lebih baik dibanding Linear Regression.



R² SCORE
0.9745

INTERPRETASI GRAFIK



Korelasi Sangat Kuat

Titik-titik data terkonsentrasi di sekitar garis merah ($y = x$), menandakan hubungan yang sangat kuat antara nilai aktual dan prediksi.



Prediksi Sangat Akurat

Sebagian besar titik berada sangat dekat dengan garis ideal, menunjukkan model mampu memprediksi harga mobil bekas dengan sangat baik.



Variasi Error Rendah

Sebaran titik menyerupai pola diagonal yang rapat, menandakan variasi error kecil dan model stabil di berbagai level harga.



Performa Model Unggul

Nilai R² sebesar 0.9745 menunjukkan 97.45% variasi harga aktual dapat dijelaskan oleh model Random Forest Regression.

KESIMPULAN



Random Forest Regression adalah model terbaik untuk memprediksi harga mobil bekas pada dataset ini, dengan akurasi tinggi dan error yang rendah.



DATASET
558,837
OBSERVATIONS



FITUR
15
FEATURES



TARGET
SELLING PRICE
(USD)



ALGORITHM
RANDOM FOREST
REGRESSION



MODELLING MENGGUNAKAN LINEAR REGRESSION



HASIL LINEAR REGRESSION



MAE

1038.605487175401

Mean Absolute Error



RMSE

1620.5135940341365

Root Mean Squared Error



R² SCORE

0.9711072129037794


Coefficient of Determination

RINGKASAN PERFORMA MODEL

Model Linear Regression menunjukkan performa yang sangat baik dalam memprediksi harga mobil bekas.



LINEAR REGRESSION: AKTUAL VS PREDIKSI



INTERPRETASI GRAFIK



Korelasi Sangat Kuat

Titik-titik data menyebar di sekitar garis merah ($y = x$), menunjukkan prediksi model sangat mendekati nilai aktual.



Prediksi Akurat

Semakin dekat titik ke garis merah, semakin kecil kesalahan prediksi. Sebagian besar titik berada sangat dekat dengan garis ideal.



Performa Model Tinggi

Nilai R² sebesar 0.9711 menandakan 97.11% variasi harga aktual dapat dijelaskan oleh model Linear Regression.



Sebaran Residual Kecil

Tidak terlihat pola sistematis yang kuat, menandakan model tidak mengalami bias yang signifikan.

KESIMPULAN



Model Linear Regression memberikan hasil prediksi yang sangat baik dan dapat diandalkan untuk estimasi harga mobil bekas.



DATA

558,837

OBSERVATIONS



FITUR

15

FEATURES



TARGET

SELLING PRICE

(USD)



ALGORITHM

LINEAR

REGRESSION



PERBANDINGAN MODEL LINEAR REGRESSION DAN RANDOM FOREST REGRESSION



RINGKASAN PERBANDINGAN METRIK

LINEAR REGRESSION

RANDOM FOREST REGRESSION

MAE
(Mean Absolute Error)

1,038.61

918.88

↓

🏆 Random Forest lebih baik (lebih rendah)

RMSE
(Root Mean Squared Error)

1,620.51

1,522.03

↓

🏆 Random Forest lebih baik (lebih rendah)

R² SCORE
(Coefficient of Determination)

0.9711

0.9745


↑

🏆 Random Forest lebih baik (lebih tinggi)

KETERANGAN METRIK

	MAE	Rata-rata absolut kesalahan prediksi.
	RMSE	Akar dari rata-rata kuadrat kesalahan prediksi.
	R² Score	Proporsi variasi data yang dapat dijelaskan oleh model.

PERBANDINGAN PERFORMA MODEL



Semakin rendah MAE & RMSE, semakin baik model.



Semakin tinggi R² Score, semakin baik model.



INTERPRETASI HASIL



Random Forest memiliki MAE lebih rendah (918.88 vs 1,038.61), artinya rata-rata kesalahan prediksi lebih kecil.



Random Forest juga memiliki RMSE lebih rendah (1,522.03 vs 1,620.51), menunjukkan penyimpangan prediksi yang lebih kecil.



Random Forest memiliki R² lebih tinggi (0.9745 vs 0.9711), yang berarti model mampu menjelaskan variasi harga mobil dengan lebih baik.



Secara keseluruhan, Random Forest Regression memberikan performa yang lebih unggul dibandingkan Linear Regression pada dataset harga mobil bekas ini.

KESIMPULAN

RANDOM FOREST REGRESSION



Model terbaik untuk prediksi harga mobil bekas pada dataset ini.



KESIMPULAN

ALUR PENELITIAN



DATASET



PREPROCESSING



EDA



LINEAR REGRESSION



RANDOM FOREST
REGRESSION



BEST PREDICTION MODEL



AI

AI

MACHINE
LEARNING



RANDOM
FOREST



ANALYTICS

HASIL PREDIKSI HARGA MOBIL

year	make	model	trim	body	transmission	state	condition	odometer
2020	Toyota	Corolla	LE	Sedan	automatic	ca	42	35000

color	interior	seller	mmr
white	black	Dealer	18500

Prediksi Harga Jual

\$19,128.50



HASIL PENELITIAN

- ✓ Dataset mobil bekas berhasil diproses melalui tahapan preprocessing dan exploratory data analysis (EDA).
- ✓ Dua algoritma regresi berhasil dibangun untuk memprediksi harga jual mobil bekas.
- ✓ Kedua model memberikan performa yang sangat baik dengan nilai R^2 di atas 97%, menunjukkan kemampuan prediksi yang tinggi.



PERBANDINGAN MODEL

Random Forest Regression menghasilkan:

- ✓ MAE lebih rendah ↓
- ✓ RMSE lebih rendah ↓
- ✓ R^2 lebih tinggi ↑

dibandingkan Linear Regression.



KESIMPULAN AKHIR

Random Forest Regression dipilih sebagai model terbaik karena mampu menghasilkan prediksi harga mobil bekas yang lebih akurat dan stabil pada dataset yang digunakan.



ARTIFICIAL
INTELLIGENCE



MACHINE
LEARNING



ANALYTICS



PREDICTION



DATASET BESAR
558,837
OBSERVASI



16
FITUR
VARIABEL



REGRESSION
SUPERVISED
LEARNING



DUA MODEL
DIBANDINGKAN



PERFORMA
SANGAT BAIK
 $R^2 > 97\%$



PREDIKSI AKURAT
DAN STABIL



FUTURE WORK



01

Current Study



02

Feature Engineering
lebih lanjut



03

Hyperparameter Tuning



04

XGBoost



05

LightGBM



06

CatBoost



07

Deep Learning
Regression



08

Deployment Web
Prediction System

OUR GOAL

Build more intelligent & accurate
used car price prediction system



GLOBAL DATA STREAM

01010110 10110010 01010101
10101010 01010110 10101010
01011010 10101001 01011010

DATA ANALYTICS



THANK YOU

Questions & Future Work

MACHINE LEARNING



PREDICTION ACCURACY



MODEL PERFORMANCE



BEST MODEL



AI

ALGORITHM

AI

NEURAL
NETWORK

AI

MACHINE
LEARNING

AI

BIG DATA

AI

ANALYTICS

REAL TIME PREDICTION



SYSTEM PERFORMANCE

ACCURACY 97.45%
PRECISION 96.80%
STABILITY 95.30%

KONTRIBUSI PENELITIAN

Penelitian ini memberikan manfaat bagi:



Dealer mobil bekas

Membantu menentukan harga
jual yang kompetitif dan optimal.



Perusahaan pembiayaan

Mendukung penilaian aset dan
analisis risiko pembiayaan.



Pengembang sistem AI

Menjadi referensi dataset dan model
untuk pengembangan sistem cerdas.



Pembeli kendaraan

Memberikan estimasi harga yang
lebih transparan dan adil.



Peneliti Machine Learning

Menjadi referensi untuk penelitian
lebih lanjut di bidang prediksi harga.

PESAN PENUTUP

Machine Learning dapat membantu menghasilkan
estimasi harga mobil bekas yang lebih objektif,
cepat, dan akurat sehingga mendukung
pengambilan keputusan yang lebih baik bagi
seluruh pemangku kepentingan.

